

Pesquisa Trilha D: Síntese e Controle de Avatares Neurais

1. Detalhe Importante: Natureza dos Modelos e Abordagem Prática

Detalhe Importante: Os modelos de ponta apresentados na literatura recente, como Vasa-1 da Microsoft, Omnihuman-1.5 da ByteDance, Audio2Photoreal da Meta e InstructAvatar, não possuem pesos de rede nem códigos-fonte liberados publicamente. O motivo justificado oficialmente pelas empresas para não liberarem esses modelos é a preocupação com o uso indevido para geração de deepfakes.

Portanto, os experimentos realizados aqui foram, de certa forma, uma 'gambiarra' técnica para conseguir reproduzir e testar esses SOTAs. Utilizamos como base o motor de código aberto do LivePortrait / Ditto (ACM MM 2025), que fornece a espinha dorsal anatômica latente (21 keypoints tridimensionais e matriz de rotação craniofacial), e implementamos diretamente sobre esse espaço os princípios matemáticos, mecanismos de controle facial, dinâmicas de olhar e acenos propostos em cada artigo.

2. Os 4 Principais Gargalos de Avatares e Como Foram Resolvidos

- 1. Boca aberta e dentes expostos no silêncio:** Modelos comuns guiados por áudio deixam a boca inerte e entreaberta quando a pessoa para de falar. Resolvemos isso aplicando uma camada de Voice Activity Detection (VAD) que força o fechamento labial estrito ($vad_alpha = 0.0$) na ausência de voz, eliminando a sensação de dentes flutuantes.
- 2. Cabeça congelada (colapso MSE):** Treinar redes neurais com erro médio quadrático tradicional faz o avatar paralisar a cabeça. Superamos esse problema com difusão estocástica (MDM), mantendo micro-movimentos orgânicos contínuos.
- 3. Avatar passivo que não reage ao interlocutor:** Adotamos a dinâmica diádica do Audio2Photoreal da Meta. Durante a fala do usuário, o avatar assume o papel de ouvinte, selando a boca e balançando a cabeça afirmativamente (head nods) em escuta ativa.
- 4. Olhar fixo de teleprompter:** Implementamos o Gaze Aversion inspirado no Omnihuman da ByteDance, no qual o avatar desvia a cabeça e os olhos para pensar antes de responder perguntas, simulando deliberação cognitiva humana.

3. O Que Cada Modelo Agrega na Prática

- **VASA-1 (Microsoft, 2024):** Síntese holística livre direto do som. Serve de baseline puro sem intervenções manuais.
- **AUHead (ICLR 2026):** Controle de músculos faciais isolados via FACS de Paul Ekman. Permite franzir a testa em foco (AU04) ou abrir um grande sorriso genuíno (AU12 e AU06).
- **InstructAvatar (AAAI 2025):** Direção cênica em texto livre (postura altiva, queixo elevado) com fechamento labial automático durante pausas.
- **Audio2Photoreal (Meta, CVPR 2024):** Dinâmica de conversa real entre duas pessoas: o avatar escuta ativamente com acenos harmônicos de cabeça e boca 100% selada.
- **OmniHuman-1.5 (ByteDance, 2025):** Arquitetura de Dois Sistemas: fonação rápida somada a mente deliberativa que desvia o olhar (Gaze Aversion) para refletir.
- **Motion Diffusion Model (MDM, ICLR 2023):** Amostragem estocástica livre que quebra a rigidez da pose média, garantindo movimentação natural contínua.

4. O Experimento Mestre: A Prova de Fogo (Grade 2x3)

Colocamos os 6 modelos lado a lado com a mesma entrada (áudio de 9.69 segundos com fala analítica, uma pausa crítica de 2.2 segundos em silêncio absoluto, e um clímax oratório final). A comparação evidenciou com clareza visual o que cada modelo melhora:

Modelo	Fase 1: Fala Inicial	Fase 2: Silêncio de 2.2s	Fase 3: Clímax	Diferencial Observado
VASA-1	Fala neutra direta.	Boca semi-aberta passiva (sem VAD).	Fala comum sem intenção.	Baseline puro de comparação.
AUHead	Cenho franzido evidente (AU04).	Relaxamento muscular gradual.	Grande sorriso Duchenne (AU12).	Expressividade muscular cirúrgica.
InstructAvatar	Postura ereta (Pitch -4.5 deg).	Lábios 100% selados (vad=0).	Queixo erguido e oratória firme.	Presença cênica e boca fechada.
Audio2Photoreal	Turno de fala normal.	2 Acenos claros (+5.5 deg) e boca selada.	Retomada suave de conversa.	Escuta ativa (concorda acenando).
OmniHuman-1.5	Foco compenetrado inicial.	Gaze Aversion: vira o rosto (-9 deg).	Foco direto frontal e queixo alto.	Desvia o olhar para pensar.
Motion Diffusion	Cinematografia estocástica viva.	Dinâmica postural orgânica contínua.	Rica amplitude angular tridimensional.	Elimina a cabeça congelada/rígida.

5. Recomendações Diretas para Decisão de Produto

Se fossemos escolher a receita ideal para colocar um avatar em produção hoje:

1. **Camada VAD Obrigatória:** Qualquer solução comercial de áudio para movimento precisa de um módulo de Voice Activity Detection. Se o som parou, o deslocamento dos lábios deve ser zerado (vad_alpha = 0.0). Isso resolve completamente o vício visual de boca entreaberta ou dentes aparentes.
2. **Para Assistentes e Atendimento Interativo:** Adotar a combinação de Audio2Photoreal com InstructAvatar. O avatar escuta o interlocutor acenando a cabeça afirmativamente e mantém os lábios fechados, gerando sensação imediata de atenção.
3. **Para Videoaulas e Apresentações Longas:** Utilizar a arquitetura cognitiva do Omnihuman com AUHead. O desvio reflexivo de olhar (Gaze Aversion) antes de responder e os sorrisos em momentos-chave removem a impressão de robô lendo texto.
4. **Custo e Latência:** O pipeline opera em tempo real na etapa de keypoints e levou cerca de 4 minutos para renderizar 10 segundos de vídeo full-HD em hardware Apple Silicon com GPU MPS. É perfeitamente viável tanto para pré-gravação quanto para servidores CUDA.