

Pesquisa Trilha D: Síntese e Controle de Avatares Neurais

Relatório Prático de Engenharia, Mecanismos Comportamentais e Decisões de Produto

1. O Contexto Real: Engenharia Reversa e Emulação dos Modelos

Importante esclarecer de imediato: A grande maioria dos modelos de ponta apresentados pela indústria (como o **VASA-1** da Microsoft, **OmniHuman-1.5** da ByteDance, **Audio2Photoreal** da Meta Reality Labs, **InstructAvatar** e **AUHead**) **não possui código-fonte nem pesos de rede liberados publicamente**. São pesquisas fechadas e proprietárias.

Por isso, o que construímos aqui é, de forma transparente, uma **engenharia pragmática de alto nível**: adotamos o motor neural de código aberto do **LivePortrait / Ditto (ACM MM 2025)** como espaço latente e base anatômica compartilhada (21 keypoints 3D implícitos + rotação $SO(3)$), e **implementamos diretamente sobre esse motor os princípios matemáticos e comportamentais de cada artigo**. Isso nos permitiu testar e comparar as ideias lado a lado sob as mesmas condições exatas.

2. Os 4 Principais Gargalos de Avatares e Como Foram Resolvidos

Ao implementar e rodar os testes, focamos em resolver os quatro defeitos que mais quebram a sensação de realismo:

- **1. Boca aberta e dentes expostos no silêncio:** Modelos tradicionais de áudio deixam a boca inerte e entreaberta quando o som para. Resolvemos isso implementando uma camada de **Voice Activity Detection (VAD)** que força o fechamento labial estrito ($vad_alpha = 0.0$) na ausência de voz.
- **2. Cabeça congelada (Colapso MSE):** Treinar modelos com erro médio quadrático faz o avatar paralisar a cabeça. Superamos isso com a **Difusão Estocástica (MDM)**, que mantém micro-movimentos orgânicos contínuos.
- **3. Avatar passivo que não reage ao interlocutor:** Adotamos a dinâmica diádica do **Audio2Photoreal (Meta)**, onde o avatar assume o papel de ouvinte, selando a boca e balançando a cabeça afirmativamente (Head Nods) enquanto ouve.
- **4. Olhar fixo de teleprompter:** Implementamos o **Gaze Aversion do OmniHuman (ByteDance)**, no qual o avatar desvia a cabeça e o olhar para cima/esquerda para 'pensar' antes de responder, simulando deliberação cognitiva humana.

3. O Que Cada Modelo Agrega na Prática

- **VASA-1 (Microsoft Research, 2024):** Síntese holística livre direto do som. Serve de referência basal pura (sem controles adicionais).
- **AUHead (ICLR 2026):** Controle de músculos faciais isolados (FACS). Permite franzir a testa em concentração (AU04) ou abrir um grande sorriso genuíno (AU12 + AU06).
- **InstructAvatar (AAAI 2025):** Direção cênica em linguagem natural ('postura ativa, queixo elevado') com fechamento labial automático em pausas.
- **Audio2Photoreal (Meta, CVPR 2024):** Diálogo entre duas pessoas: o avatar escuta ativamente com acenos harmônicos de cabeça e boca 100% selada.
- **OmniHuman-1.5 (ByteDance, 2025):** Arquitetura de Dois Sistemas: reflexo fonético rápido + mente deliberativa que desvia o olhar (Gaze Aversion) para refletir.
- **Motion Diffusion Model (MDM, ICLR 2023):** Quebra do colapso da pose média via amostragem estocástica livre, garantindo movimento vivo e solto.

4. O Experimento Mestre: 'A Prova de Fogo' (Grade 2x3)

Colocamos os 6 modelos lado a lado com a **exata mesma entrada** (áudio de 9.69s com fala concentrada, uma pausa crítica de 2.2s de silêncio absoluto, e um clímax oratório final). Isso evidenciou com clareza visual o que cada modelo melhora:

Modelo	Fase 1: Fala Inicial	Fase 2: Silêncio de 2.2s	Fase 3: Clímax	Diferencial Observado
VASA-1	Fala neutra direta.	Boca semi-aberta passiva (sem VAD).	Fala comum sem intenção.	Baseline puro de comparação.
AUHead	Cenho franzido (AU04=0.85).	Relaxamento gradual muscular.	Grande sorriso Duchenne (AU12).	Expressividade muscular cirúrgica.
InstructAvatar	Postura ereta (Pitch -4.5 deg).	Labios 100% selados (vad=0).	Queixo erguido e oratória firme.	Presença de palco e boca fechada.
Audio2Photoreal	Turno de fala normal.	2 Acenos claros (+5.5 deg) + boca selada.	Retomada suave de conversa.	Escuta ativa (concorda acenando).
OmniHuman-1.5	Foco compenetrado inicial.	Gaze Aversion: vira o rosto (-9 deg).	Foco direto frontal e queixo alto.	Desvia o olhar para pensar.
Motion Diffusion	Cinematografia estocástica viva.	Dinâmica postural orgânica contínua.	Rica amplitude angular tridimensional.	Elimina a cabeça congelada/rígida.

5. Recomendações Diretas para Decisão de Produto

Se fossemos escolher a 'receita de bolo' ideal para colocar um avatar em produção hoje:

- 1. Camada VAD Obrigatória:** Qualquer motor de fala precisa ter um limitador de VAD (Voice Activity Detection). Se o usuário parou de falar ou o avatar fez uma pausa, o sistema deve zerar o deslocamento labial (vad_alpha = 0.0). Isso acaba definitivamente com a impressão de boca aberta ou dentes flutuantes.
- 2. Para Assistentes e Atendimento Interativo:** Adotar a dinâmica do **Audio2Photoreal + InstructAvatar**. O avatar escuta o cliente acenando com a cabeça e mantém os lábios fechados. Isso gera empatia imediata.
- 3. Para Aulas e Apresentações Longas:** Usar a arquitetura cognitiva do **OmniHuman-1.5 com AUHead**. O desvio de olhar reflexivo (Gaze Aversion) antes de responder dúvidas e os sorrisos em momentos-chave removem a sensação de 'robô lendo texto'.
- 4. Viabilidade Técnica:** Todo o pipeline roda em tempo real na etapa de keypoints e levou ~4 minutos para renderizar 10 segundos de vídeo full-HD no chip Apple Silicon via GPU MPS. É perfeitamente escalável em servidores de produção.