

Bacharelado em Inteligência Artificial

2ª Lista - NLP 2026

VERSÃO DOS ALUNOS

Lista de exercícios - 22 questões

Parte I - Questões de Múltipla Escolha

22 questões. Assinale a alternativa correta em cada questão.

Questão 1 Post-training: DPO e RLHF com PPO

Enunciado

Um modelo passou por SFT e será posteriormente alinhado utilizando dados de preferência humana. Sobre as diferenças entre **DPO e RLHF com PPO**, assinale a alternativa correta.

- A) No DPO, preferências são incorporadas diretamente na otimização da policy em relação a uma referência; no PPO, um Reward Model fornece sinal de recompensa e um Value Model auxilia na estimativa da vantagem.
- B) No DPO, a policy aprende comparando respostas escolhidas e rejeitadas, enquanto a reference policy fornece diretamente uma recompensa escalar utilizada para calcular a vantagem antes da atualização dos parâmetros.
- C) No DPO, respostas escolhidas são tratadas como exemplos de SFT, enquanto respostas rejeitadas regularizam a policy; no PPO, a reference policy substitui o Reward Model na avaliação da qualidade das respostas.
- D) No DPO, o Reward Model permanece congelado durante a otimização da policy, enquanto no PPO ele é atualizado juntamente com o Value Model para acompanhar as mudanças produzidas pela policy.
- E) No DPO, a diferença entre chosen e rejected determina a vantagem usada na atualização, enquanto no PPO essa vantagem é obtida diretamente da diferença entre a policy atual e a reference policy.

Questão 2 Post-training: GRPO

Enunciado

No **Group Relative Policy Optimization (GRPO)**, várias respostas são geradas para um mesmo prompt e recebem recompensas. Sobre como essas recompensas são utilizadas na atualização da policy, assinale a alternativa correta.

- A) As recompensas são usadas diretamente como vantagens de cada resposta, enquanto um Value Model estima uma baseline adicional para reduzir a variância durante a atualização da policy.

- B) As recompensas são convertidas em probabilidades sobre as respostas do grupo, e essas probabilidades substituem o probability ratio usado para limitar mudanças excessivas na nova policy.
- C) As recompensas são comparadas com a Reference Model para calcular a vantagem de cada resposta, enquanto a média do grupo funciona apenas como regularização adicional durante o treinamento.
- D) As recompensas são agregadas em um único valor médio para o prompt, e esse mesmo valor é multiplicado pelas probabilidades de todas as respostas geradas pela policy.
- E) As recompensas do grupo são normalizadas entre si para produzir vantagens relativas, permitindo comparar as respostas sem depender de um Value Model separado para estimar a baseline.

Questão 3 Efficient Adaptation: PEFT e LoRA

Enunciado

Considere uma camada linear com pesos $W_0 \in \mathbb{R}^{d \times k}$. Em LoRA, define-se uma atualização de baixa-rank dada por

$$\Delta W = BA,$$

com $B \in \mathbb{R}^{d \times r}$, $A \in \mathbb{R}^{r \times k}$ e $r \ll \min(d, k)$. Durante o treinamento, a saída da camada pode ser escrita como

$$h = W_0 x + \frac{\alpha}{r} B A x.$$

Considerando a formulação original de LoRA, assinale a alternativa correta sobre a parametrização e a inicialização do método.

- A) W_0 permanece congelada; A é inicializada com zeros e B aleatoriamente, fazendo com que $\Delta W = 0$ no início, enquanto apenas A e B recebem gradientes.
- B) W_0 permanece treinável; A é inicializada aleatoriamente e B com zeros, fazendo com que $\Delta W = 0$ no início, enquanto apenas A e B recebem gradientes.
- C) W_0 permanece congelada; A é inicializada aleatoriamente e B com zeros, fazendo com que $\Delta W = 0$ no início, enquanto apenas A e B recebem gradientes.
- D) W_0 permanece congelada; A é inicializada aleatoriamente e B com zeros, fazendo com que $\Delta W = BA$ no início, enquanto apenas A e B recebem gradientes.
- E) W_0 permanece congelada; A é inicializada aleatoriamente e B com zeros, fazendo com que $\Delta W = 0$ no início, enquanto apenas W_0 e B recebem gradientes.

Questão 4 Agentes: Ciclo de Ação, Observação e Verificação

Enunciado

Um agente de programação recebeu a tarefa de corrigir um parser de CSV. Durante a execução, ele: 1. lê os arquivos do repositório;

2

Bacharelado em Inteligência Artificial NLP 2026

2. identifica uma possível causa;
3. modifica o código;
4. executa alguns testes;
5. recebe como observação que 18 testes passaram e 2 falharam;
6. afirma: “A correção está concluída”.

Considerando uma arquitetura de agentes baseada em modelo, runtime, ambiente, ações e observações, assinale a alternativa correta.

- A) Como a modificação já foi realizada no ambiente, a afirmação final do modelo deve ser considerada evidência suficiente de que a tarefa foi concluída.
- B) Os dois testes que falharam constituem novas instruções do usuário e, portanto, devem substituir o objetivo original armazenado pelo agente.
- C) A execução dos testes faz parte do raciocínio interno do modelo, pois ferramentas utilizadas por agentes são apenas extensões da geração de tokens.
- D) O resultado dos testes é uma observação do ambiente que deve atualizar o estado disponível ao agente; a tarefa só deve ser considerada concluída se os critérios externos de sucesso forem satisfeitos.
- E) O runtime deveria impedir novas chamadas ao modelo após a primeira modificação, pois ciclos de ação e observação caracterizam treinamento, não inferência.

Questão 5 Tool Use: Seleção de Ferramentas

Enunciado

Um agente dispõe das seguintes ferramentas:

```
calculator(expression)
search_documents(query)
get_customer_balance(customer_id)
```

O usuário pergunta:

“Tenho R\$ 8.420,00 de saldo. Acho que clientes da categoria X recebem 7,5% de desconto segundo o regulamento. Quanto sobraria depois do desconto?”

O agente deve responder com base no regulamento vigente, evitando chamadas desnecessárias de ferramentas e sem assumir como verdadeiro um dado normativo apenas porque foi mencionado pelo usuário.

Qual comportamento é conceitualmente mais adequado?

- A) Utilizar calculator diretamente com 7,5%, pois o percentual informado pelo usuário pode ser

tratado como parte do contexto da conversa, e consultar o regulamento apenas se o usuário questionar o resultado.

- B)** Consultar `get_customer_balance` para validar o saldo informado pelo usuário, depois consultar `search_documents` para verificar o percentual e, por fim, utilizar `calculator`.

3

Bacharelado em Inteligência Artificial NLP 2026

- C)** Consultar `search_documents` para verificar a regra vigente da categoria X e, se o percentual for confirmado, utilizar `calculator` com o saldo já fornecido pelo usuário; `get_customer_balance` só seria necessário se houvesse motivo para validar o saldo externo.
- D)** Consultar `search_documents` e `get_customer_balance` em paralelo, independentemente de o saldo já ter sido informado, pois dados obtidos por ferramentas devem sempre ter precedência sobre informações fornecidas diretamente pelo usuário.
- E)** Consultar `search_documents` para obter o percentual e pedir ao próprio modelo que realize mentalmente o cálculo, pois a ferramenta `calculator` deve ser reservada para operações matemáticas que não possam ser resolvidas pelo LLM.

Questão 6 RAG: Recuperação Híbrida e Reranking

Enunciado

Um sistema RAG é utilizado para responder perguntas sobre uma base de manuais técnicos. O corpus apresenta duas características importantes:

- alguns documentos contêm identificadores específicos, como E17, TRF-9921 e códigos de equipamentos;
- muitas perguntas dos usuários descrevem um problema utilizando palavras diferentes das empregadas no manual.

Nos testes, observou-se que o BM25 frequentemente recupera melhor documentos quando há termos técnicos exatos, enquanto o dense retriever frequentemente recupera melhores documentos semanticamente relacionados quando existe pouca sobreposição lexical.

A equipe pretende utilizar também um cross-encoder como reranker.

Qual das estratégias abaixo é a mais adequada?

- A)** Executar BM25 e dense retrieval, aplicar o cross-encoder separadamente aos resultados de cada retriever e escolher exclusivamente a lista cujo primeiro documento receber o maior score do reranker.
- B)** Executar BM25 e dense retrieval, unir ou fundir seus candidatos, remover eventuais duplicatas e aplicar o cross-encoder sobre esse conjunto reduzido antes de selecionar os documentos enviados ao LLM.
- C)** Executar primeiro o dense retriever, aplicar o cross-encoder e utilizar BM25 apenas para reordenar os documentos que permanecerem empatados após o reranking.
- D)** Executar BM25 e dense retrieval, aplicar o cross-encoder a todos os documentos do corpus e utilizar os dois retrievers apenas para definir a ordem em que os documentos serão avaliados.
- E)** Utilizar BM25 para gerar candidatos, aplicar o cross-encoder e depois executar dense re

trieval apenas sobre os documentos descartados pelo reranker, recuperando documentos semanticamente semelhantes aos rejeitados.

Questão 7 Modelos Multimodais: Fusão Early

Enunciado

4

Bacharelado em Inteligência Artificial NLP 2026


Um desafio muito comum em abordagens multimodais é a fusão, que pode ser dada de acordo com o estágio em que ela ocorre, sendo eles, *early*, *late* e *hybrid*. Acerca dos benefícios da fusão *early*, assinale a **única** alternativa correta.

- A) Permite o uso de modelos distintos e otimizados para cada modalidade, conferindo maior flexibilidade ao modelo.
- B) Facilita a predição quando uma ou mais modalidades estão ausentes, bem como o treinamento quando não há dados paralelos disponíveis.
- C) Explora correlações e interações entre *features* de baixo nível das modalidades, podendo ser vista como uma forma inicial de aprendizado de representação multimodal.
- D) Combina as saídas da fusão de características com preditores unimodais individuais, aproveitando as vantagens dos dois estágios em um mesmo *framework*.
- E) Funde as decisões (classificação ou regressão) de cada modalidade por características estatísticas como média, votação ou ponderação por ruído do canal.

Questão 8 Representações Multimodais: Conjunta e Coordenada

Enunciado

Na figura, a representação conjunta pode ser expressa por $x_m = f(x_1, \dots, x_n)$ e a coordenada por $f(x_1) \sim g(x_2)$. Acerca dessas formulações, julgue os itens.



- I. Na representação conjunta, a representação multimodal é computada por uma única função f que depende de todas as representações unimodais.
- II. Na representação coordenada, cada modalidade possui sua própria função de projeção, e o símbolo $\sim$ indica uma restrição de similaridade ou de estrutura entre os espaços resultantes.
- III. Na representação coordenada, a projeção de cada modalidade depende das demais modalidades.
- IV. São exemplos de coordenação: minimizar a distância de cosseno ou maximizar a correlação.
- V. Representações coordenadas são mais usadas em tarefas em que todas as modalidades

estão presentes, como descrição de imagens.

É correto o que se afirma em:

- A) I e II.
- B) II e III.
- C) I, III e IV.

5

Bacharelado em Inteligência Artificial NLP 2026

- D) I, II e V.
- E) I, II e IV.

Questão 9 Modelos Multimodais: CLIP e Representação Coordenada

Enunciado

O CLIP (*Contrastive Language-Image Pre-training*) é um modelo multimodal treinado com pares (imagem, texto). A respeito de sua relação com os tipos de representação multimodal, assinale a **única** alternativa correta.

- A) A coordenação é implementada pela minimização da distância de cosseno apenas entre os pares verdadeiros, sendo os demais pares do batch tratados como ignoráveis pela função de perda.
- B) Cada encoder projeta sua representação por uma transformação linear para o espaço de embeddings, seguida de normalização L_2 . A coordenação é imposta pela função objetivo contrastiva simétrica sobre a matriz de similaridades escalada, permanecendo a projeção de cada modalidade independente da outra.
- C) A maximização da similaridade de cosseno entre embeddings normalizados é matematicamente equivalente ao objetivo de correlação canônica (CCA/DCCA), de modo que o CLIP captura exclusivamente a informação compartilhada entre as modalidades, descartando a informação específica de cada uma.
- D) O parâmetro de temperatura que escala os *logits* da matriz de similaridades é um hiperparâmetro fixado antes do treinamento, pois sua otimização comprometeria a estabilidade da perda contrastiva.
- E) No uso *zero-shot*, o classificador final é obtido por *fine-tuning* supervisionado do encoder de imagem sobre os embeddings de texto das classes do conjunto de teste.

Questão 10 Modelos Multimodais: Cross-Attention

Enunciado

A camada de *self-attention* pode ser modificada de diversas maneiras para atender o problema de interação/fusão multimodal. Considerando a *cross-attention* definida por

$$\begin{cases} Z_{(A)} \leftarrow \text{MHSA}(Q_B, K_A, V_A), \\ Z_{(B)} \leftarrow \text{MHSA}(Q_A, K_B, V_B). \end{cases}$$

Assinale apenas a alternativa correta.

- A)** As duas sequências de *tokens* são concatenadas antes da atenção, o que eleva a complexidade computacional para $O((N_{(A)} + N_{(B)})^2)$.
- B)** A atenção é realizada globalmente sobre o contexto completo das duas modalidades, e cada ramo preserva *self-attention* ao seu próprio contexto interno.
- C)** A troca das *queries* entre os ramos faz com que cada modalidade seja atendida condicionada à outra, sem aumento da complexidade computacional.
- D)** A formulação caracteriza uma interação *late*, pois as modalidades são codificadas de forma totalmente independente e não trocam informação entre si.

- E)** A troca das *queries* projeta as duas modalidades em um mesmo espaço comum, configurando uma representação conjunta.

Questão 11 Post-Training: SFT, DPO e RLHF

Enunciado

Uma equipe está realizando o post-training de um LLM. O modelo pré-treinado M_0 foi submetido às seguintes etapas:

- **Etapa 1 (SFT):** o modelo foi treinado com demonstrações produzidas por especialistas, com tendo instruções e respostas consideradas ideais.
- **Etapa 2 (Preferências):** a partir do modelo obtido após SFT, foram geradas duas respostas para cada prompt, e avaliadores humanos escolheram qual resposta consideravam melhor.
- **Etapa 3 (DPO):** os pares chosen/rejected foram utilizados para continuar o treinamento, tendo o modelo após SFT como reference policy.

Ao final, foram obtidos os seguintes resultados:

Modelo Acurácia factual Instruction Following Preferência humana M_0

71% 44% 39%

Após SFT 74% 81% 63%

Após DPO 62% 88% 79%

Durante o DPO, a loss de treinamento diminuiu normalmente. Uma análise posterior dos dados revelou, entretanto, que respostas mais curtas e assertivas eram escolhidas com frequência pelos avaliadores, inclusive em alguns casos nos quais a resposta rejeitada apresentava uma justificativa mais completa e factualmente correta.

Diante desses resultados, um engenheiro propõe substituir o DPO por RLHF utilizando PPO, argumentando que o uso de um Reward Model resolveria a queda de acurácia factual.

Analise o experimento e proponha como a equipe deveria proceder. Em sua resposta, desenvolva o raciocínio a partir das diferentes etapas do pipeline e aborde obrigatoriamente:

1. o que os resultados após SFT sugerem sobre o comportamento aprendido pelo modelo;
2. como a loss do DPO pode diminuir e a preferência humana aumentar enquanto a acurácia factual diminui;
3. em qual componente do pipeline está a explicação mais provável para esse comportamento;
4. se substituir DPO por RLHF com PPO resolveria necessariamente o problema;
5. qual mudança deveria ser realizada antes de um novo treinamento e qual experimento poderia testar a hipótese proposta.

Questão 12 Post-Training: DPO, PPO e GRPO

Enunciado

Considere três estratégias de post-training utilizadas para incorporar preferências ou sinais de recompensa em modelos de linguagem: **DPO**, **PPO** e **GRPO**.

Explique, de forma comparativa, como cada uma dessas estratégias realiza a atualização do modelo. Em sua resposta, destaque:

1. qual tipo de sinal é utilizado para orientar o treinamento;
2. se há necessidade de um Reward Model explícito;
3. se há necessidade de um Value Model;
4. como a vantagem ou preferência é obtida em cada método.

Não é necessário apresentar as fórmulas completas das funções de loss.

Questão 13 Efficient Adaptation: LoRA e Matrizes de Baixo Rank

Enunciado

Considere uma camada linear de um Transformer cuja matriz de pesos original é

$$W_0 \in \mathbb{R}^{4096 \times 4096}.$$

Em vez de atualizar diretamente W_0 , deseja-se utilizar LoRA com rank $r = 8$. A atualização é representada por

$$\Delta W = BA,$$

de modo que

$$W = W_0 + \Delta W.$$

Responda às questões abaixo, justificando seus cálculos:

1. Quais devem ser as dimensões das matrizes A e B para que o produto BA tenha as mesmas dimensões de W_0 ?
2. Quantos parâmetros treináveis são introduzidos por LoRA nesse caso? Compare esse valor com os 4096×4096 parâmetros que seriam treinados caso toda a matriz W_0 fosse atualizada.
3. Considere agora um vetor de entrada $x \in \mathbb{R}^{4096}$. Descreva as dimensões do vetor após as operações Ax e $B(Ax)$. Explique o papel do rank $r = 8$ nesse caminho.
4. Suponha que o rank seja aumentado de $r = 8$ para $r = 64$. Explique qualitativamente o que muda em relação à quantidade de parâmetros treináveis e à capacidade de representação da atualização ΔW .

Questão 14 Tool Use: Planejamento e Atualização do Estado do Agente

Enunciado

Um assistente universitário possui três ferramentas:

```
buscar_regulamento(pergunta)
consultar_matricula(id_aluno)
calcular(expressao)
```

Um aluno pergunta:

“No sistema aparecem 68 horas de atividades complementares. Quantas ainda faltam para eu cumprir a exigência do curso?”

O agente sabe, a partir de seu conhecimento paramétrico, que versões anteriores do regulamento exigiam 100 horas. Entretanto, ao consultar a base institucional, `buscar_regulamento` retorna dois documentos:

- um regulamento de 2023, que estabelece 100 horas;
- uma resolução de 2026, que estabelece 120 horas para alunos ingressantes a partir de determinado período.

O agente ainda não sabe o período de ingresso do estudante.

Explique como o agente deveria proceder até produzir uma resposta confiável.

Em sua resposta, aborde:

1. quais informações podem ser consideradas observações válidas em cada etapa;
2. quais informações ainda precisam ser obtidas antes do cálculo;
3. quais ferramentas devem ser utilizadas e em que ordem;
4. em que situação `consultar_matricula` passa a ser necessária, mesmo que o aluno já tenha informado as 68 horas;
5. como o agente deve tratar a existência de dois documentos normativos aparentemente aplicáveis;
6. em que momento o cálculo pode ser realizado;
7. por que seria incorreto escolher simplesmente a regra de 100 ou 120 horas com base no conhecimento prévio do modelo;
8. qual deveria ser o comportamento do agente caso não consiga determinar com segurança qual regulamento se aplica ao aluno.

Questão 15 RAG: Diagnóstico de Falhas em Diferentes Estágios do Pipeline

Enunciado

Um sistema RAG responde perguntas sobre regulamentos institucionais utilizando o seguinte pipeline:

Query → Dense Retriever (top-50) → Cross-Encoder Reranker (top-5) → seleção de trechos → construção

doPara a pergunta:

“Qual é o prazo para recurso após o resultado preliminar?”

a resposta final do sistema foi “10 dias”, mas a resposta correta no regulamento vigente é “5 dias úteis”.

Os logs da execução mostram:

- o documento correto estava na posição 34 após o dense retrieval;

10

Bacharelado em Inteligência Artificial NLP 2026

- após o reranking, esse documento passou para a posição 3;
- entre os cinco documentos selecionados, havia também um regulamento antigo que mencionava prazo de 10 dias;
- o trecho do documento vigente contendo “5 dias úteis” foi recuperado;
- o prompt final continha trechos dos dois regulamentos;
- o LLM respondeu apenas “O prazo é de 10 dias”.

Com base nesse cenário, analise o pipeline.

Em sua resposta:

1. avalie separadamente o desempenho do retriever e do reranker;
2. explique por que a presença do documento correto no contexto não é suficiente para concluir que o sistema de recuperação funcionou perfeitamente;
3. identifique pelo menos duas possíveis fontes de erro após o reranking;
4. discuta como a seleção ou organização dos trechos no prompt pode ter contribuído para o erro;
5. explique como distinguir uma falha de retrieval, uma falha de context construction e uma falha de generation;
6. indique métricas ou avaliações que poderiam ser usadas separadamente para cada uma dessas etapas;
7. explique por que avaliar apenas se a resposta final está certa ou errada é insuficiente para diagnosticar esse sistema;
8. proponha uma alteração experimental que permita verificar se o principal problema está na seleção do contexto ou no comportamento do LLM.

Questão 16 RAG: Projeto de um Pipeline Híbrido

Enunciado

Você precisa construir um sistema RAG para uma empresa cujo corpus apresenta as seguintes características:

- documentos contendo códigos como TRF-9921, E17, nomes de equipamentos e números de norma;
- perguntas dos usuários frequentemente formuladas com vocabulário semanticamente diferente do utilizado nos documentos;
- aproximadamente 2 milhões de chunks.

Projete um pipeline de recuperação e geração adequado para esse cenário. Em sua resposta, discuta obrigatoriamente:

1. por que utilizar somente BM25 pode ser insuficiente;

2. por que utilizar somente dense retrieval também pode ser insuficiente;
3. como combinar os dois tipos de recuperação;

11

Bacharelado em Inteligência Artificial NLP 2026

4. o papel de um método de fusão como Reciprocal Rank Fusion (RRF);
5. por que utilizar um reranker após a recuperação inicial;
6. por que não aplicar um cross-encoder diretamente aos 2 milhões de chunks;
7. como escolher o contexto final enviado ao LLM;
8. pelo menos três pontos diferentes do pipeline em que uma resposta incorreta pode ser

introduzida. **Questão 17 Flamingo: Perceiver Resampler e Atenção Cruzada**

Enunciado

No Flamingo, o *Perceiver Resampler* recebe as características espaço-temporais produzidas pelo codificador visual e as transforma em um número fixo de *tokens* visuais. Considere um vídeo representado por T quadros, com S características espaciais por quadro e dimensão embutida d . Após a adição das codificações temporais e o achatamento dos eixos temporal e espacial, seja

$$X_f \in \mathbb{R}^{T \times S \times d}.$$

considere também R latentes aprendidos,

$$H^{(0)} \in \mathbb{R}^{R \times d},$$

e uma camada do Resampler definida por

$$C^{(\ell)} = [X_f, H^{(\ell)}],$$

Os vetores de *queries*, *keys* e *values* sejam definidos por:

$$Q^{(\ell)} = H^{(\ell)} W^{(\ell)} \quad K, V^{(\ell)} = C^{(\ell)} W^{(\ell)}$$

ou,

A atenção é definida por

$$Q, K^{(\ell)} = C^{(\ell)} W^{(\ell)} \quad \left(\begin{array}{c} \end{array} \right)$$

dada por:

$$Q^{(\ell)} K^{(\ell)\top} \frac{1}{d_h}$$

$$A^{(\ell)} = \text{softmax}$$

E por fim, a saída é

$$H^{(\ell+1)} = H^{(\ell+1)} + \text{FFN}^{(\ell)}(H^{(\ell+1)}).$$

$$\tilde{H}^{(\ell+1)} = H^{(\ell)} + A^{(\ell)} V^{(\ell)} W^{(\ell)}$$

Assuma que as características visuais e os latentes já foram projetados para a mesma dimensão d . Para a análise de complexidade, desconsidere as projeções lineares, a rede *feed-forward* e as constantes associadas ao número de cabeças, salvo quando solicitado. Considerando a arquitetura original temos que $R = 64$.

Responda, justificando cada etapa:

- (a) Determine as dimensões de $C^{(\ell)}$, $Q^{(\ell)}$, $K^{(\ell)}$, $V^{(\ell)}$, $A^{(\ell)}$ e $H^{(\ell+1)}$ para uma única cabeça de atenção. Explique por que a quantidade de tokens produzidos pelo Resampler não depende de T nem de S .
- (b) Explique o papel distinto de X_f e $H^{(\ell)}$ como fontes de informação para a atenção. Em particular, indique o que mudaria na matriz de atenção se as chaves e os valores fossem calculados somente a partir de X_f , sem concatenar os latentes.

- (c) Considere uma entrada com três elementos visuais intercalados com texto:

$\langle \text{imagem}_1 \rangle y_1 \langle \text{vídeo}_2 \rangle y_2 \langle \text{imagem}_3 \rangle y_3$.

Suponha que cada elemento visual seja processado separadamente pelo Resampler e produza R tokens. Defina uma função $\phi(\ell)$ que indique o índice do elemento visual mais recente antes do token de texto y_ℓ . Especifique, por meio de uma máscara, quais tokens visuais podem ser acessados diretamente por y_ℓ na atenção cruzada. Explique como informações de elementos visuais anteriores ainda podem influenciar a geração posterior, mesmo que a atenção cruzada direta de um token textual seja restrita ao elemento visual mais recente.

Parte III - Código / Implementação

5 questões. Em cada questão, o enunciado informa a quantidade exata de erros relevantes. Considere corretos os imports, modelos, funções auxiliares e objetos cuja implementação não é mostrada. Não considere diferenças de estilo, eficiência ou sintaxe equivalente como erros, a menos que alterem o comportamento esperado. Para cada erro identificado, indique o trecho ou decisão incorreta, explique sua consequência e apresente uma correção. Não é necessário reescrever todo o programa, salvo se isso ajudar a explicar a resposta.

Questão 18 RAG: Ordem do Pipeline e Uso do Contexto

Enunciado

Um sistema RAG recebe uma pergunta, indexa uma coleção de documentos, recupera os k documentos mais relacionados à pergunta e utiliza o conteúdo recuperado para produzir a resposta.

Considere que o objeto índice começa vazio. A função `indice.adicionar(vetores, textos)` adiciona documentos ao índice, e `indice.buscar(vetor, k)` retorna os k textos mais similares entre os documentos que já estão armazenados. A função `montar_prompt(pergunta, contexto)` também está implementada corretamente.

O código abaixo possui **exatamente 2 erros de lógica**. Identifique-os, explique a consequência de cada um e mostre como corrigi-los.

```
def responder_rag(
    pergunta,
    documentos,
    encoder,
    indice,
    llm,
    k=2
):
    q_vec = encoder.encode(pergunta)

    recuperados = indice.buscar(q_vec, k)

    doc_vecs = encoder.encode(documentos)
    indice.adicionar(doc_vecs, documentos)

    contexto = "\n".join(recuperados)

    prompt = montar_prompt(
        pergunta,
        contexto
    )

    return llm(pergunta)
```

Questão 19 Vision Transformers: Preparação da Sequência

Enunciado

O código abaixo representa, de forma simplificada, a etapa de classificação de uma imagem com um Vision Transformer (ViT). Considere que `patch_embed(imagem)` produz a sequência de embeddings dos patches, `adicionar_cls_token(...)` adiciona o token de classificação no início da sequência, `pos_embeddings` contém embeddings posicionais compatíveis com a sequência completa e `classifier` recebe a representação final do token de classificação.

Todas as funções auxiliares estão corretas. O código possui **exatamente 2 erros conceituais de ordem**. Identifique-os, explique a consequência de cada um e mostre como reorganizar as operações.

```

def classificar_imagem(
    imagem,
    patch_embed,
    cls_token,
    pos_embeddings,
    transformer,
    classifier
):
    x = patch_embed(imagem)

    x = transformer(x)

    x = adicionar_cls_token(
        x,
        cls_token
    )

    x = x + pos_embeddings

    return classifier(x[0])

```

Questão 20 Agentes e Uso de Ferramentas

Enunciado

Considere um agente que pode utilizar as ferramentas `buscar_base(query)` e `calculadora(expression)`. Em cada chamada, `llm(...)` pode produzir uma resposta final ou uma solicitação de ferramenta em `resposta.tool_call`. Cada solicitação contém `call.name`, o nome da ferramenta; `call.arguments`, um dicionário com os argumentos produzidos pelo modelo; e `call.id`, o identificador da chamada.

O agente pode precisar utilizar uma ou mais ferramentas antes de produzir a resposta final. Considere que `resposta.as_message()` e `tool_message()` já estão implementados corretamente.

O código abaixo possui **exatamente 2 erros conceituais/lógicos**. Identifique-os, explique como eles alteram o comportamento do agente e apresente as correções necessárias.

```

def responder_agente(pergunta):
    mensagens = [
        {"role": "user", "content": pergunta}
    ]

    while True:
        resposta = llm(
            mensagens,
            tools=TOOL_SCHEMAS
        )

        if resposta.tool_call is None:
            return resposta.text

        call = resposta.tool_call

        resultado = TOOLS[call.name](pergunta)

        mensagens.append(
            resposta.as_message()

```

```
mensagens.append(
    tool_message(call.id, resultado)
)

return resultado
```

Questão 21 Modelos Multimodais: CLIP e Espaço Compartilhado

Enunciado

Um sistema deve receber uma descrição textual e escolher, entre várias imagens, aquela semanticamente mais compatível utilizando CLIP.

Considere que `encode_images_clip(...)` retorna embeddings de imagem normalizados produzidos pelo ramo visual do CLIP, e `encode_text_clip(...)` retorna embeddings textuais normalizados do mesmo CLIP. O objeto `text_encoder` é outro encoder textual, treinado de forma independente, que por coincidência produz vetores normalizados com a mesma dimensionalidade dos embeddings do CLIP. Portanto, o código abaixo executa sem erro de dimensão.

O código possui **exatamente 2 erros conceituais/lógicos**. Identifique-os, explique a consequência de cada um para a busca multimodal e apresente uma correção.

```
def imagem_mais_compativel(
    texto,
    imagens,
    clip_model,
    processor,
    text_encoder
):
    image_vecs = encode_images_clip(
        clip_model,
        processor,
        imagens
    )

    text_vec = text_encoder.encode(
        texto,
        normalize=True
    )

    scores = image_vecs @ text_vec

    indice = scores.argmax()

    return imagens[indice]
```

Questão 22 Pós-treinamento: DPO com LoRA/PEFT

Enunciado

O código abaixo representa um treinamento simplificado de DPO com LoRA. Considere que `get_peft_model(...)` insere os adaptadores LoRA corretamente e que `dpo_loss(...)` já implementa corretamente o objetivo matemático do DPO. Essa função recebe explicitamente uma `policy`, uma `ref_model`, o `prompt`, a resposta preferida em `chosen` e a resposta não preferida em `rejected`.

O código executa, mas possui **exatamente 3 erros conceituais importantes** no pipeline de treinamento. Identifique-os, explique por que cada um é incompatível com DPO e/ou PEFT e apresente as alterações necessárias.

```
base_model = load_model()

policy = get_peft_model(
    base_model,
    lora_config
)

ref_model = copy.deepcopy(policy)
ref_model.eval()

for p in ref_model.parameters():
    p.requires_grad = False

for p in policy.parameters():
    p.requires_grad = True

optimizer = AdamW(
    policy.parameters(),
    lr=1e-4
)

def train_step(batch):
    optimizer.zero_grad()
    losses = []

    for ex in batch:
        loss_ex = dpo_loss(
            policy=policy,
            ref_model=ref_model,
            prompt=ex["prompt"],
            chosen=ex["rejected"],
            rejected=ex["chosen"]
        )

        losses.append(loss_ex)

    loss = torch.stack(losses).mean()

    loss.backward()
    optimizer.step()

    ref_model.load_state_dict(
        policy.state_dict()
    )

    return loss.item()
```